

**KLASIFIKASI NOMINAL UANG KERTAS RUPIAH
MENGGUNAKAN METODE *HISTOGRAM OF ORIENTED
GRADIENTS (HOG)* DAN *SUPPORT VECTOR MACHINE*
(SVM)**

LAPORAN PROYEK PENGELOLAAN CITRA



Disusun Oleh :

Moh. Ulil Abror Abdallah (210411100166)

PRODI TEKNIK INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS TRUNOJOYO MADURA 2025

DAFTAR ISI

DAFTAR ISI.....	1
DAFTAR GAMBAR.....	3
ABSTRAK.....	4
BAB 1. PENDAHULUAN.....	5
1.1. Latar Belakang.....	5
1.2. Rumusan Masalah.....	6
1.3. Batasan Masalah.....	6
Untuk memastikan penelitian berjalan lebih terarah, batasan masalah yang diberikan adalah sebagai berikut:.....	6
1.4. Tujuan Penelitian.....	7
1.5. Alur Kerja CRISP-DM.....	7
BAB II: BUSINESS UNDERSTANDING.....	8
2.1. Konteks Permasalahan.....	8
2.2. Tujuan Bisnis (Business Objectives).....	10
2.3. Tujuan Pembelajaran Mesin.....	10
2.4. Kriteria Keberhasilan.....	11
3.1. Sumber Data.....	12
3.2. Struktur Fitur dan Label.....	12
3.3. Eksplorasi Data (Exploratory Data Analysis).....	14
3.4. Permasalahan Data.....	16
BAB IV: DATA PREPARATION.....	17
4.1. Pembersihan dan Penyeragaman Data (Data Cleaning).....	18
4.2. Transformasi Citra (Image Transformation).....	18
4.3. Rekayasa Fitur.....	20
4.4. Pembagian Data (Data Splitting).....	22
4.5. Dataset Final.....	23
BAB V: MODELING.....	23
5.1. Pemilihan Algoritma.....	24
5.2. Skema Pelatihan (Training Scheme).....	25
5.3. Hasil Pelatihan.....	26
BAB 6: EVALUATION.....	27
6.1. Evaluasi Menggunakan Metrik Statistik.....	27
6.2. Analisis Kesalahan (Error Analysis).....	29
6.3. Evaluasi Terhadap Tujuan Bisnis.....	29
6.4. Model Final.....	30
BAB 7: DEPLOYMENT.....	30

7.1. Bentuk Implementasi Sistem.....	30
7.2. Mekanisme Interaksi dan Alur Penggunaan Sistem (User Interaction Mechanism).....	32
7.3. Dokumentasi Alur Data (Data Pipeline Architecture).....	34
BAB 8: KESIMPULAN DAN SARAN.....	36
DAFTAR PUSTAKA.....	38

DAFTAR GAMBAR

- **Gambar 3.1** Contoh Sampel Citra Uang Rupiah Emisi 2022 dari Dataset.
- **Gambar 4.1** Perbandingan Citra Asli dengan Hasil Penskalaan (*Resizing*).
- **Gambar 4.2** Visualisasi Konversi Ruang Warna RGB ke *Grayscale*.
- **Gambar 4.3** Hasil Segmentasi Biner Menggunakan Metode Otsu.
- **Gambar 4.4** Visualisasi Hasil Deteksi Tepi Canny.
- **Gambar 4.5** Visualisasi Deskriptor Fitur *Histogram of Oriented Gradients* (HOG).
- **Gambar 4.6** Diagram Lingkaran Proporsi Pembagian Data Latih dan Uji.
- **Gambar 5.1** Diagram Alir (*Flowchart*) Arsitektur Sistem Klasifikasi.
- **Gambar 6.1** Matriks Kebingungan (*Confusion Matrix*) Hasil Pengujian Model.
- **Gambar 7.1** Tampilan Antarmuka Pengguna Aplikasi Deteksi Uang.

ABSTRAK

Identifikasi nominal uang kertas Rupiah yang dikeluarkan secara terbaru memberikan tantangan tersendiri, terutama bagi penyandang disabilitas penglihatan dan sistem otomasi di perbankan. Hal ini disebabkan oleh keseragaman ukuran fisik dan kompleksitas visual yang tinggi pada uang tersebut. Metode Deep Learning seperti Convolutional Neural Network (CNN) biasanya menghadapi kendala dalam hal kebutuhan sumber daya komputasi yang besar, sehingga kurang efektif untuk diterapkan pada perangkat dengan spesifikasi yang terbatas. Penelitian ini bertujuan untuk membangun model klasifikasi nominal uang Rupiah yang efisien dan akurat dengan menggunakan pendekatan Machine Learning konvensional.

Metode yang digunakan menggabungkan teknik pengolahan citra digital dengan algoritma pembelajaran mesin. Citra uang kertas yang berasal dari dataset sekunder melalui tahapan pra-pemrosesan, yaitu penskalaan ke resolusi 128 x 128 piksel, konversi ke warna abu-abu (grayscale), serta deteksi tepi menggunakan metode Canny untuk menonjolkan struktur geometris dari objek tersebut. Proses ekstraksi fitur dilakukan dengan metode Histogram of Oriented Gradients (HOG) untuk menangkap pola bentuk dan tekstur lokal. Fitur yang diperoleh kemudian direduksi dimensinya menggunakan Principal Component Analysis (PCA) untuk mempercepat proses komputasi. Pengklasifikasian akhir dilakukan dengan menggunakan algoritma Support Vector Machine (SVM) dengan kernel Radial Basis Function (RBF).

Hasil pengujian menunjukkan bahwa model yang dikembangkan mampu mengenali tujuh kelas nominal uang Rupiah dengan performa yang baik, membuktikan bahwa kombinasi HOG dan SVM dapat menjadi alternatif solusi yang ringan secara komputasi. Namun, analisis kesalahan menunjukkan penurunan akurasi pada pecahan Rp10.000 yang dikarenakan hilangnya informasi warna pada tahap pra-pemrosesan. Hal ini menjadi catatan penting untuk pengembangan sistem di masa depan.

Kata Kunci: Klasifikasi Citra, Uang Rupiah, Histogram of Oriented Gradients (HOG), Support Vector Machine (SVM), Pengolahan Citra Digital.

BAB I

PENDAHULUAN

1.1. Latar Belakang

Uang kartal, terutama uang kertas, merupakan alat penting dalam berbagai transaksi ekonomi sehari-hari di Indonesia. Setiap pecahan mata uang Rupiah memiliki ciri visual yang berbeda, mulai dari warna dominan, desain, hingga angka nominal yang digunakan untuk membedakan antara satu pecahan dengan yang lain. Bagi orang yang memiliki penglihatan normal, proses mengenali nilai uang bisa dilakukan secara cepat dan mudah. Namun, bagi penyandang disabilitas netra atau dalam kondisi cahaya yang kurang, proses ini bisa menjadi sulit. Identifikasi uang secara sentuh pun bisa terganggu karena kondisi fisik uang yang rusak atau tidak rapi.

Dengan berkembangnya teknologi Computer Vision, sistem pengenalan objek secara otomatis menjadi jawaban yang potensial untuk mengatasi tantangan tersebut. Saat ini, pendekatan Deep Learning seperti Convolutional Neural Network (CNN) menjadi tren utama dalam klasifikasi gambar karena kemampuannya yang tinggi dalam mengenali objek. Namun, implementasi CNN membutuhkan sumber daya komputasi yang besar, seperti memori dan GPU, serta dataset dalam jumlah besar untuk proses pelatihan yang optimal. Ini menjadi kendala ketika sistem ingin digunakan di perangkat dengan spesifikasi terbatas atau biaya rendah.

Oleh karena itu, dibutuhkan metode alternatif yang lebih efisien dalam aspek komputasi namun tetap efektif dalam mengenali pola visual. Penelitian ini mengusulkan penggunaan metode Machine Learning tradisional dengan menggabungkan ekstraksi fitur Histogram of Oriented Gradients (HOG) dan algoritma klasifikasi Support Vector Machine (SVM). Metode HOG dipilih karena kemampuannya dalam merepresentasikan bentuk dan tekstur objek melalui distribusi arah gradien, yang relatif tidak tergantung pada perubahan cahaya. Sementara itu, SVM dipilih karena kemampuannya dalam mengklasifikasikan data di ruang berdimensi tinggi meskipun hanya dengan jumlah sampel yang terbatas.

Dengan pendekatan ini, diharapkan dapat dikembangkan sistem pengenalan nominal uang Rupiah yang ringan, cepat, dan akurat.

Selanjutnya, sistem tersebut akan diimplementasikan dalam bentuk antarmuka aplikasi web sederhana sebagai bentuk uji coba atau validasi sistem.

1.2. Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, rumusan masalah dalam penelitian ini adalah sebagai berikut:

- a. Bagaimana cara merancang tahapan pra-pemrosesan gambar yang tepat untuk mengatur variasi gambar uang kertas Rupiah sebagai input?
- b. Bagaimana efektivitas metode Histogram of Oriented Gradients (HOG) dalam mengekstrak fitur visual berupa bentuk dan tekstur dari gambar uang Rupiah?
- c. Bagaimana tingkat keakuratan algoritma Support Vector Machine (SVM) dalam mengklasifikasikan tujuh jenis nominal uang kertas Rupiah?
- d. Bagaimana merancang tampilan awal (prototype) aplikasi berbasis web yang dapat menguji fungsionalitas model klasifikasi yang telah dilatih?

1.3. Batasan Masalah

Untuk memastikan penelitian berjalan lebih terarah, batasan masalah yang diberikan adalah sebagai berikut:

- a. Objek penelitian meliputi tujuh pecahan uang kertas Rupiah yang diterbitkan terbaru, yaitu Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, dan Rp100.000.
- b. Format input berupa file gambar digital dengan ekstensi JPG, PNG, atau JPEG.
- c. Resolusi gambar akan diatur secara seragam menjadi 128 x 128 piksel dengan tujuan meningkatkan efisiensi dalam proses komputasi.
- d. Implementasi sistem dilakukan menggunakan bahasa pemrograman Python dan framework Streamlit.
- e. Tujuan dari penelitian ini adalah untuk membangun prototipe sistem yang cerdas dan mampu mengenali nominal uang Rupiah secara otomatis.

- f. Manfaat yang diperoleh meliputi adanya alternatif metode deteksi objek yang ringan, sehingga dapat berjalan di perangkat dengan CPU standar, serta potensi pengembangan lebih lanjut menjadi alat bantu aksesibilitas atau modul kasir otomatis.

1.4. Tujuan Penelitian

Penelitian ini bertujuan untuk:

- a. Membuat model klasifikasi yang mampu mengenali nominal uang kertas Rupiah berdasarkan ekstraksi fitur HOG dan metode klasifikasi SVM.
- b. Mengevaluasi kinerja model berdasarkan parameter akurasi guna mengetahui tingkat efektivitas metode yang digunakan.
- c. Mengimplementasikan model klasifikasi ke dalam bentuk aplikasi antarmuka berbasis web yang dapat melakukan prediksi nominal uang secara real-time.

1.5. Alur Kerja CRISP-DM

Penyelesaian proyek ini mengacu pada kerangka kerja standar Cross-Industry Standard Process for Data Mining (CRISP-DM) untuk memastikan proses penelitian dilakukan secara sistematis dan terukur. Berikut tahapan implementasinya:

1. **Tahap Business Understanding:** Fokus pada pemahaman terhadap pentingnya pengembangan sistem deteksi uang otomatis sebagai alat bantu untuk meningkatkan aksesibilitas dan efisiensi, serta menetapkan kriteria keberhasilan dengan membangun model yang ringan namun tetap akurat.
2. **Tahap Data Understanding:** Melakukan pengumpulan data sekunder berupa dataset gambar uang Rupiah edisi baru, serta melakukan analisis awal (Exploratory Data Analysis) untuk memahami distribusi kelas dan karakteristik visual dari data tersebut.
3. **Tahap Data Preparation:** Melakukan beberapa teknik pra-pemrosesan citra seperti penskalaan ukuran gambar (resizing), konversi format ruang warna, serta deteksi tepi (edge detection) untuk mempersiapkan data agar optimal saat diolah oleh algoritma.
4. **Tahap Modeling:** Membangun arsitektur model klasifikasi dengan melakukan ekstraksi fitur menggunakan HOG, reduksi dimensi dengan Principal Component Analysis (PCA), serta pelatihan model SVM dengan optimasi parameter hyperparameter.

5. **Tahap Evaluation:** Mengukur kinerja model dengan menggunakan metrik evaluasi standar seperti akurasi dan matriks kebingungan (confusion matrix), serta menganalisis pola kesalahan prediksi (misclassification) yang terjadi pada kelas bernama tertentu.
6. **Tahap Deployment:** Mengimplementasikan model yang telah divalidasi ke dalam antarmuka aplikasi web dengan menggunakan kerangka kerja Streamlit agar dapat diakses dan diuji coba oleh pengguna akhir.

BAB II

BUSINESS UNDERSTANDING

2.1. Konteks Permasalahan

Uang kartal, terutama uang kertas, masih menjadi alat pembayaran utama dalam sistem transaksi mikro di Indonesia, meskipun sistem pembayaran digital terus berkembang. Kemampuan untuk mengenali nilai uang secara cepat dan tepat merupakan syarat penting dalam memastikan lancarnya dan keamanan transaksi ekonomi sehari-hari. Namun, realitas di lapangan menunjukkan adanya kesenjangan dalam akses serta kendala teknis yang signifikan, terutama berkaitan dengan karakteristik fisik uang Rupiah yang diterbitkan tahun 2022.

Permasalahan utama yang menjadi dasar dari pelaksanaan proyek ini dapat dijelaskan sebagai berikut:

1. **Hambatan Aksesibilitas bagi Penyandang Disabilitas Netra** Meskipun Bank Indonesia telah menambahkan fitur keamanan berupa kode tuna netra (blind code) dalam bentuk garis taktil di bagian uang, efektivitas fitur tersebut sangat tergantung pada kondisi fisik uang. Dalam proses peredaran, uang kertas bisa mengalami perubahan kualitas fisik seperti rusak, kusam, atau basah, sehingga tekstur taktil tersebut bisa memudar atau hilang. Hal ini memaksa penyandang disabilitas netra tergantung pada bantuan orang lain saat melakukan transaksi, sehingga mengurangi kemandirian mereka secara finansial dan meningkatkan potensi penipuan. Selain itu, keseragaman ukuran fisik antar pecahan pada emisi baru—meskipun memiliki perbedaan panjang, tetapi tidak terlalu signifikan—meningkatkan kesulitan dalam pengenalan berdasarkan rabaan semata.
2. **Keterbatasan Sumber Daya pada Perangkat Komputasi Tepi (Edge Devices)** Dalam bidang kecerdasan buatan, pendekatan Deep Learning seperti Convolutional Neural Network (CNN) saat ini menjadi standar terbaik untuk klasifikasi gambar karena akurasinya yang tinggi. Namun, arsitektur CNN memiliki kompleksitas komputasi yang besar, membutuhkan unit pemrosesan

grafis (GPU) berkinerja tinggi dan memori yang besar untuk menyimpan model. Hal ini menjadi hambatan serius jika sistem ingin diaplikasikan pada perangkat berbiaya rendah atau perangkat bergerak dengan spesifikasi terbatas. Solusi yang ada terkadang terlalu berat dan boros energi untuk digunakan secara luas di masyarakat.

3. **Urgensi Efisiensi Waktu dan Latensi Rendah** Baik dalam konteks alat bantu visual maupun sistem pembayaran otomatis (seperti mesin penjual otomatis sederhana), kecepatan pengenalan merupakan faktor utama. Pengguna mengharapkan respons yang segera (real-time). Metode klasifikasi yang terlalu rumit sering kali menyebabkan jeda waktu (latensi) yang lama saat proses inferensi, yang mengganggu pengalaman pengguna. Oleh karena itu, dibutuhkan algoritma yang mampu menyeimbangkan antara akurasi yang diterima dengan kecepatan pemrosesan yang tinggi, tanpa memberatkan perangkat keras.
4. **Tantangan dalam Identifikasi Visual di Lingkungan yang Tidak Ideal.** Masalah dalam mengenali nilai uang tidak hanya dialami oleh penyandang disabilitas, tetapi juga oleh masyarakat umum dalam kondisi lingkungan tertentu, misalnya pada saat pencahayaan rendah seperti malam hari atau ketika uang terkena noda. Beberapa pecahan uang Rupiah baru memiliki palet warna yang memiliki kesamaan dalam tingkat rona (hue) tertentu, sehingga sulit untuk dibedakan oleh sensor kamera standar dalam kondisi pencahayaan rendah. Oleh karena itu, diperlukan metode ekstraksi fitur yang lebih mengandalkan struktur dan bentuk, seperti HOG, dibandingkan hanya mengandalkan informasi warna saja.

2.2. Tujuan Bisnis (Business Objectives)

Berdasarkan masalah yang telah dijelaskan, tujuan dari pengembangan sistem ini tidak hanya terbatas pada pembuatan perangkat lunak, tetapi lebih terfokus pada dampak dari penerapan teknologi tersebut, yaitu:

1. Peningkatan Kemandirian Finansial bagi Penyandang Disabilitas: Sistem ini menyediakan solusi teknologi bantuan yang dapat diandalkan dan mudah digunakan (user-friendly) untuk membantu penyandang disabilitas netra dalam mengidentifikasi nilai uang secara mandiri, tanpa harus bergantung

- sepenuhnya pada bantuan orang lain. Hal ini dapat mengurangi risiko kerugian finansial akibat kesalahan pengenalan atau penipuan.
2. Efisiensi Biaya Infrastruktur Teknologi: Sistem ini menawarkan alternatif solusi pengenalan objek yang lebih hemat biaya. Berbeda dengan sistem berbasis Deep Learning yang memerlukan investasi perangkat keras yang mahal (seperti GPU), sistem ini dirancang agar dapat beroperasi secara optimal pada perangkat komputasi standar atau perangkat embedded yang harga belinya lebih terjangkau. Dengan demikian, sistem ini menurunkan hambatan biaya (barrier to entry) dalam menerapkan teknologi ini secara lebih luas, seperti pada usaha mikro, kecil, dan menengah (UKM).
 3. Validasi Konsep untuk Integrasi Sistem: Pengembangan ini menghasilkan sebuah purwarupa (prototype) yang telah diverifikasi sebagai dasar untuk pengembangan lebih lanjut dalam integrasi sistem pembayaran otomatis, seperti pada mesin jual otomatis atau kios mandiri, yang membutuhkan respons cepat serta konsumsi daya yang rendah.

2.3. Tujuan Pembelajaran Mesin

Untuk mewujudkan tujuan bisnis tersebut dalam bentuk langkah-langkah teknis, tujuan pembelajaran mesin dalam proyek ini ditetapkan sebagai berikut:

1. Kontruksi Model Klasifikasi Multi-Kelas: Membuat model pembelajaran yang didasarkan pada pengawasan (supervised learning) untuk mengklasifikasikan citra uang kertas menjadi tujuh kategori yang berbeda, yaitu Rp1.000, Rp2.000, Rp5.000, Rp10.000, Rp20.000, Rp50.000, dan Rp100.000, dengan kemampuan untuk beradaptasi dan berfungsi baik pada data baru.
2. Pengekstrakan Fitur Berbasis Bentuk dan Tekstur: Mengevaluasi kinerja metode Histogram of Oriented Gradients (HOG) dalam mengekstrak informasi visual penting seperti pola angka dan desain ornamen dari citra uang yang telah diubah ke dalam format skala abu-abu dan ukuran resolusinya dikurangi, sebagai pengganti informasi warna yang hilang.
3. Pengoptimalan Batas Keputusan (Decision Boundary): Menggunakan algoritma Support Vector Machine (SVM) dengan metode pencarian parameter terbaik secara sistematis (Grid Search) pada kernel Radial Basis Function (RBF), untuk mengatasi kesulitan dalam memisahkan data citra yang memiliki

kompleksitas tinggi dan tidak dapat dipisahkan secara garis lurus (non-linearly separable) dalam ruang fitur berdimensi tinggi.

2.4. Kriteria Keberhasilan

Keberhasilan proyek ini akan diukur berdasarkan parameter kuantitatif dan kualitatif sebagai berikut:

1. Metrik Akurasi Model: Model diharapkan memiliki akurasi pengujian (testing accuracy) minimal 65%. Angka tersebut ditetapkan sebagai ambang batas yang moderat, mengingat adanya tantangan teknis seperti penggunaan resolusi gambar yang rendah (128x128 piksel) serta kehilangan fitur warna pada tahap pra-pemrosesan.
2. Efisiensi Waktu Inferensi (Real-Time Performance): Sistem mampu memproses input gambar mulai dari proses pengunggahan hingga menampilkan hasil prediksi dalam waktu kurang dari 3 detik per gambar pada lingkungan komputasi standar (CPU). Hal ini sangat penting untuk menjaga pengalaman pengguna (user experience) agar tetap responsif.
3. Stabilitas Identifikasi Kelas: Model diharapkan mampu mengenali pecahan uang dengan fitur visual yang jelas, seperti pecahan Rp100.000 dan Rp50.000, dengan tingkat kesalahan (False Negative Rate) di bawah 10%. Untuk pecahan dengan tekstur yang mirip, seperti pecahan Rp10.000, sistem tetap diharapkan memberikan prediksi yang konsisten meskipun dengan toleransi kesalahan yang lebih tinggi, dan hasilnya akan dianalisis lebih lanjut pada tahap evaluasi.

BAB III

DATA UNDERSTANDING

3.1. Sumber Data

Dalam pelaksanaan proyek akhir ini, data yang digunakan diklasifikasikan sebagai data sekunder. Data sekunder berarti data yang telah dikumpulkan, diatur, dan dipublikasikan oleh pihak lain, kemudian digunakan kembali untuk keperluan penelitian tanpa harus mengumpulkan data langsung di lapangan.

Sumber utama dataset diperoleh dari platform repositori data sains yang terpercaya, yaitu Kaggle. Dataset yang digunakan dalam penelitian ini berjudul "Uang Emisi 2022 Baru", yang dipublikasikan oleh Fanny Zahrah Ramadhan. Penentuan dataset ini didasarkan pada berbagai pertimbangan akademis dan teknis yang sangat penting, yaitu:

1. Relevansi Waktu: Dataset ini berisi gambar uang kertas Rupiah Tahun Emisi (TE) 2022. Hal ini sangat penting karena uang emisi baru memiliki ciri fisik dan visual yang berbeda secara signifikan dibandingkan emisi sebelumnya (TE 2016). Dengan demikian, model yang dibuat akan selalu sesuai dan up-to-date dengan kondisi uang yang beredar di masyarakat saat ini.
2. Perbedaan Kondisi Pengambilan: Gambar dalam dataset ini tidak diambil dalam kondisi studio yang terkontrol, tetapi mewakili kondisi nyata di dunia nyata. Data mencakup berbagai sudut pengambilan, tingkat cahaya yang beragam (dari terang hingga gelap), serta latar belakang yang berbeda. Keragaman ini sangat membantu dalam meningkatkan kemampuan model untuk menangani berbagai situasi (robustness) dan mengurangi kecenderungan model untuk terlalu spesifik pada pola latar belakang tertentu.
3. Ketersediaan Publik: Dataset ini memiliki lisensi publik yang memungkinkan penggunaan untuk tujuan pendidikan dan penelitian akademis. Hal ini sesuai dengan standar etika penggunaan data dalam penyusunan laporan ilmiah.

3.2. Struktur Fitur dan Label

Pemahaman tentang struktur data mentah sangat penting untuk menentukan strategi pra-pemrosesan yang tepat. Dataset ini berupa data tidak terstruktur

(unstructured data) berupa citra digital yang diorganisasi dalam direktori berbasis kelas.

3.2.1. Struktur Fitur (Features)

Fitur masukan (Input Features) dalam dataset ini merupakan kumpulan citra digital uang kertas dengan karakteristik teknis seperti berikut:

1. Format File: Citra disimpan dalam format kompresi standar .jpg (JPEG) atau .png (Portable Network Graphics).
2. Dimensi Spasial: Resolusi asli citra bervariasi, tetapi umumnya memiliki dimensi tinggi (High Definition). Setiap citra mewakili matriks tiga dimensi (Height x Width x Channels).
3. Ruang Warna: Citra mentah berada dalam ruang warna RGB (Red, Green, Blue), di mana setiap piksel diwakili oleh tiga nilai kanal warna dengan tingkat intensitas berada dalam rentang bilangan bulat 0-255 (format 8-bit).
4. Kandungan Informasi: Fitur mentah ini mengandung informasi piksel yang sangat kaya namun juga memiliki tingkat noise yang tinggi. Informasi visual mencakup tekstur kertas uang, pola air (watermark), angka nominal, benang pengaman, serta ornamen batik. Selain objek utama yaitu uang, fitur juga mencakup informasi latar belakang seperti meja, lantai, atau tangan, yang perlu dipisahkan pada tahap berikutnya.

3.2.2. Struktur Label (Target Variable)

Variabel target (Label) yang akan diprediksi oleh model adalah data kategorikal nominal. Masalah ini didefinisikan sebagai Klasifikasi Multi-Kelas (Multi-Class Classification), di mana setiap sampel citra hanya memiliki satu label kebenaran (ground truth).

Dataset ini terdiri dari 7 (tujuh) kelas label, yang mewakili seluruh pecahan uang kertas Rupiah yang sah dan beredar saat ini, yaitu:

1. Kelas '1000': Mewakili pecahan Rp1.000 (Seribu Rupiah).
2. Kelas '2000': Mewakili pecahan Rp2.000 (Dua Ribu Rupiah).
3. Kelas '5000': Mewakili pecahan Rp5.000 (Lima Ribu Rupiah).
4. Kelas '10000': Mewakili pecahan Rp10.000 (Sepuluh Ribu Rupiah).

5. Kelas '20000': Mewakili pecahan Rp20.000 (Dua Puluh Ribu Rupiah).
6. Kelas '50000': Mewakili pecahan Rp50.000 (Lima Puluh Ribu Rupiah).
7. Kelas '100000': Mewakili pecahan Rp100.000 (Seratus Ribu Rupiah).

Secara teknis, label ini disimpan dalam bentuk nama folder (string). Dalam proses pemodelan selanjutnya, label teks akan diubah menjadi format numerik (0 hingga 6) menggunakan teknik Label Encoding agar dapat diproses oleh algoritma matematis seperti SVM.

3.3. Eksplorasi Data (*Exploratory Data Analysis*)

Sebelum memasuki tahap pemodelan, dilakukan analisis data awal (Exploratory Data Analysis - EDA) untuk memahami bagaimana data terdistribusi, pola yang muncul, serta anomali yang ada dalam dataset. Memahami karakteristik data secara mendalam sangat penting agar dapat menentukan strategi pra-pemrosesan yang tepat.

3.3.1 Distribusi Frekuensi Kelas

Analisis pertama difokuskan pada distribusi jumlah gambar dalam setiap kelas. Dalam konteks pembelajaran terarah (Supervised Learning), keseimbangan data merupakan faktor penting. Dataset ini dibagi ke dalam tujuh folder kelas, yaitu dari Rp1.000 hingga Rp100.000.

Berdasarkan hasil observasi pada direktori penyimpanan, jumlah gambar dalam setiap kelas tergolong seragam. Keseimbangan ini merupakan indikator positif, karena model Support Vector Machine (SVM) sangat rentan terhadap ketidakseimbangan kelas (imbalanced dataset). Dengan perbandingan data yang seimbang, model tidak akan memiliki bias untuk secara terus-menerus memprediksi kelas mayoritas semata, sehingga metrik akurasi yang dihasilkan nantinya akan mencerminkan kinerja model secara objektif.

3.3.2 Analisis Karakteristik Visual

Dilihat secara visual, uang kertas Rupiah edisi 2022 memiliki fitur yang khas, tetapi juga memiliki tantangan dalam pemrosesan:

1. Fitur Bentuk dan Angka

Setiap pecahan memiliki angka nominal yang besar dan tegas, dengan kontras tinggi terhadap latar belakang uang. Bentuk geometris dari angka-angka ini (seperti lengkungan pada angka '0', '5', dan '2') merupakan fitur yang sangat kuat dan cocok untuk dideteksi oleh algoritma deteksi tepi (edge detection).

2. Pola Ornamen

Dalam uang kertas tersebut terdapat pola batik serta garis-garis halus (guilloche) yang rumit. Pola ini menghasilkan tekstur yang cukup kompleks, sehingga cocok untuk diekstraksi menggunakan metode Histogram of Oriented Gradients (HOG).

3. Dominasi Warna

Setiap pecahan memiliki warna dominan yang berbeda (Merah untuk Rp100.000, Biru untuk Rp50.000, Hijau untuk Rp20.000, Ungu untuk Rp10.000, Cokelat untuk Rp5.000, Abu-abu untuk Rp2.000, dan Hijau Kekuningan untuk Rp1.000). Informasi warna ini sangat kuat dalam format citra RGB, namun berpotensi hilang ketika dikonversi ke format citra keabuan



Gambar 3.1 Contoh Sampel Citra Uang

3.4. Permasalahan Data

Berdasarkan hasil eksplorasi yang telah dilakukan, beberapa permasalahan pokok pada data mentah ditemukan dan perlu diatasi melalui teknik pra-pemrosesan (Data Preparation) agar model dapat berjalan secara optimal:

3.4.1. Tingginya Dimensi Fitur (High Dimensionality)

Citra digital dalam dataset ini memiliki resolusi yang cukup tinggi. Sebuah citra dengan resolusi standar smartphone (misalnya 1000 x 1000 piksel) memiliki 1 juta titik data per channel. Jika langsung dimasukkan ke dalam algoritma SVM, hal ini akan menyebabkan fenomena "Kutukan Dimensi" (Curse of Dimensionality). Dampak: Waktu pelatihan model akan meningkat secara eksponensial, dan memori komputer berisiko mengalami kelebihan beban (overflow).

Solusi yang Diperlukan: Citra perlu dikurangi resolusinya menjadi ukuran yang lebih kecil (128x128 piksel) dan dimensi fitur dapat direduksi menggunakan Principal Component Analysis (PCA).

3.4.2. Gangguan Latar Belakang

Karena citra diambil dalam kondisi nyata, objek uang tidak selalu mengisi seluruh bingkai foto. Ada area latar belakang seperti tekstur meja, lantai, atau tangan yang juga tercatat dalam citra. Dampak: Jika tidak dipisahkan, algoritma HOG akan mengekstraksi tekstur latar belakang sebagai bagian dari fitur uang. Ini dapat membingungkan model (misleading features) dan mengurangi akurasi. Solusi yang Diperlukan: Teknik segmentasi thresholding (Metode Otsu) diterapkan untuk memisahkan Region of Interest (ROI) uang dari latar belakangnya.

3.4.3. Ambiguitas Intensitas pada Skala Keabuan (Grayscale Ambiguity)

Tantangan khusus ditemukan pada pecahan uang Rp10.000 (Ungu). Dalam ruang warna RGB, warna ungu sangat berbeda dengan warna abu-abu (Rp2.000) atau cokelat (Rp5.000). Namun, ketika diconversi menjadi citra keabuan (grayscale) berdasarkan luminansinya, intensitas warna ungu sering kali memiliki nilai keabuan yang hampir sama dengan pecahan lainnya. Dampak: Model berpotensi mengalami kesalahan klasifikasi (misclassification) dalam membedakan Rp10.000 dengan Rp2.000 atau Rp5.000 karena hilangnya fitur utama yang membedakan (warna). Solusi yang Diperlukan: Deteksi tepi (Canny Edge Detection) diterapkan untuk menonjolkan fitur bentuk angka nominal sebagai pengganti informasi warna yang telah hilang.

BAB IV

DATA PREPARATION

Tahap persiapan data (*Data Preparation*) merupakan fase krusial dalam siklus CRISP-DM untuk mengubah data mentah menjadi format yang siap diproses oleh algoritma pemodelan. Dalam penelitian ini, data citra uang Rupiah melalui serangkaian proses transformasi bertingkat untuk menstandarisasi input dan menonjolkan fitur-fitur visual yang relevan.

4.1. Pembersihan dan Penyeragaman Data (Data Cleaning)

Data citra mentah yang diperoleh dari dataset memiliki karakteristik beragam, baik dari segi resolusi spasial maupun rasio lebar-tinggi. Dalam algoritma pembelajaran mesin berbasis vektor, seperti Support Vector Machine (SVM), konsistensi dimensi input merupakan syarat mutlak karena setiap citra harus diubah menjadi vektor fitur dengan panjang yang sama. Oleh karena itu, langkah pertama yang dilakukan adalah proses penskalaan gambar (image resizing). Citra asli yang memiliki resolusi tinggi (beragam di atas 1000 piksel) diubah resolusinya (downsampling) menjadi dimensi tetap 128 x 128 piksel. Pemilihan ukuran 128 x 128 piksel didasarkan pada pertimbangan efisiensi komputasi. Penggunaan resolusi asli akan menghasilkan jumlah fitur yang sangat besar, sehingga membebani memori dan memperlambat proses pelatihan model. Meskipun terjadi pengurangan informasi detail, ukuran 128 x 128 terbukti secara empiris masih mempertahankan karakteristik umum uang kertas, seperti bentuk angka nominal dan pola umum, yang cukup untuk dikenali oleh algoritma HOG.



Gambar 4.1 Resize

4.2. Tranformasi Citra (Image Transformation)

Setelah dimensi citra diseragamkan, dilakukan beberapa transformasi untuk memperjelas fitur penting (Region of Interest) dan menghilangkan informasi yang tidak relevan (noise).

4.2.1. Konversi Ruang Warna (Grayscale)

Citra awal biasanya berada dalam ruang warna RGB yang terdiri dari tiga saluran matriks.

Pada tahap ini, citra dikonversi ke bentuk skala abu-abu (grayscale) dengan hanya satu saluran intensitas. Konversi ini dilakukan menggunakan persamaan luminansi standar:

$$Y = 0.299R + 0.587G + 0.114B.$$

Tujuannya adalah mengurangi kompleksitas data hingga 1/3 dan memfokuskan ekstraksi fitur pada informasi intensitas cahaya, seperti tekstur dan bentuk, bukan pada variasi warna yang rentan terhadap kondisi pencahayaan.



Gambar 4.2 Grayscale

4.2.2. Deteksi Tepi (Canny Edge Detection)

Proses transformasi terakhir adalah ekstraksi kontur menggunakan algoritma Canny Edge Detection. Algoritma ini mendeteksi perubahan intensitas piksel yang tajam (gradien tinggi) untuk membentuk garis tepi. Hasil dari proses ini adalah citra yang hanya berisi garis-garis sketsa dari angka nominal, benang pengaman, dan ornamen batik utama. Citra tepi ini merupakan input ideal

untuk deskriptor HOG karena telah bebas dari gangguan warna dan detail tekstur yang tidak perlu.



Gambar 4.3 Canny Edge

4.2.3. Segmentasi Ambang Batas (Otsu's Thresholding)

Citra uang kertas seringkali mengandung latar belakang yang tidak relevan, seperti tekstur meja atau bayangan. Untuk memisahkan objek uang (foreground) dari latar belakang, digunakan metode Otsu's Thresholding. Metode ini bekerja secara adaptif dengan menghitung histogram citra dan mencari nilai ambang batas yang optimal agar varians intra-kelas diminimalkan. Piksel dengan intensitas di atas ambang batas akan diubah menjadi putih (objek), sedangkan piksel di bawah ambang batas akan diubah menjadi hitam (latar belakang), menghasilkan citra biner yang bersih.



Gambar 4.4 Otsu's Thresholding.

4.3. Rekayasa Fitur

Setelah citra mengalami transformasi visual menjadi citra tepi (edge map), data tersebut masih berupa matriks piksel mentah. Tahap rekayasa fitur bertujuan untuk

mengonversi data spasial tersebut menjadi vektor numerik yang merepresentasikan karakteristik unik (fingerprint) dari setiap pecahan uang, sekaligus mereduksi redundansi data.

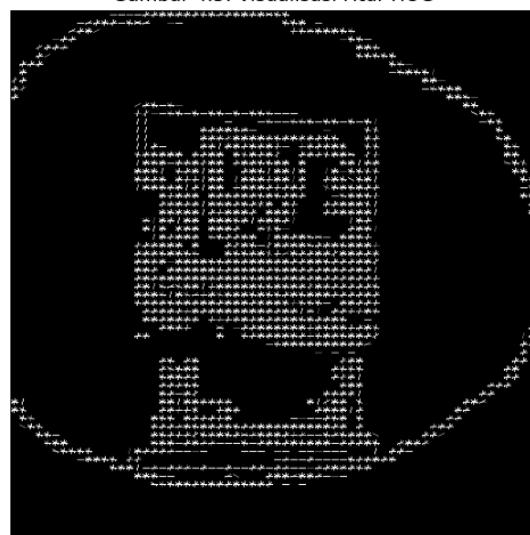
4.3.1. Ekstraksi Fitur Histogram of Oriented Gradients (HOG)

Ekstraksi fitur dilakukan menggunakan metode Histogram of Oriented Gradients (HOG). Berbeda dengan metode berbasis warna yang rentan terhadap perubahan pencahayaan, HOG bekerja dengan memetakan distribusi arah gradien (perubahan intensitas) lokal. Konfigurasi parameter HOG yang digunakan adalah:

- a. Orientations: 9 (jumlah bin histogram arah).
- b. Pixel per cell: (8, 8).
- c. Cells per block: (2, 2). Parameter ini dipilih agar dapat menangkap detail lokal yang cukup dari pola uang kertas tanpa menghasilkan vektor fitur yang terlalu besar.

Keluaran dari proses ini adalah satu vektor fitur panjang (feature vector) untuk setiap citra yang berisi ribuan nilai numerik, yang merepresentasikan "bentuk" dari uang tersebut secara matematis.

Gambar 4.5: Visualisasi Fitur HOG



Gambar 4.5 Visualisasi Fitur HOG

4.3.2. Reduksi Dimensi dengan PCA

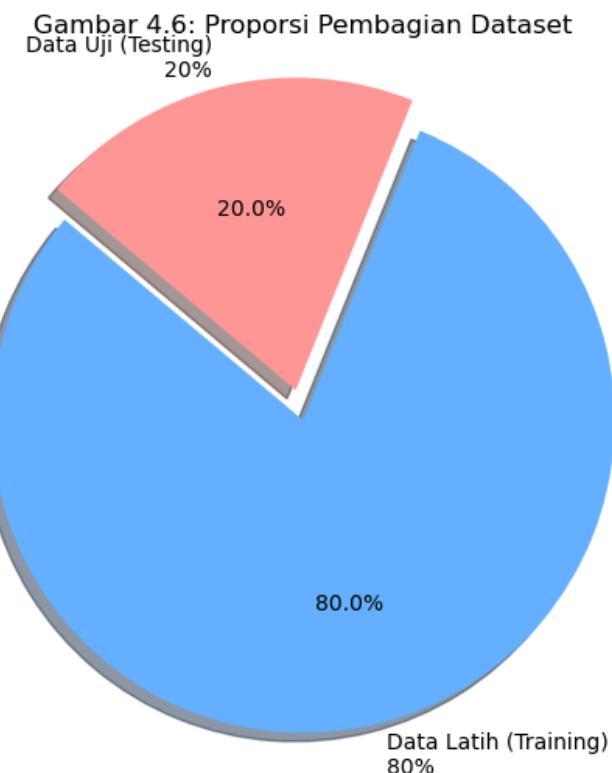
Vektor fitur yang dihasilkan oleh HOG memiliki dimensi yang sangat tinggi. Untuk mencegah overfitting dan mempercepat proses pelatihan, diterapkan Principal Component Analysis (PCA). PCA

mentransformasikan fitur-fitur tersebut ke dalam komponen-komponen utama dan mereduksi dimensinya dengan tetap mempertahankan sebagian besar variansi informasi dari data asli.

4.4. Pembagian Data (Data Splitting)

Untuk memastikan evaluasi model dilakukan secara objektif dan mencegah terjadinya kebocoran data (data leakage), dataset dibagi menjadi dua bagian yang terpisah menggunakan teknik Stratified Random Sampling. Teknik ini dipilih agar proporsi kelas nominal (Rp1.000 sampai Rp100.000) tetap seimbang, baik pada data latih maupun data uji.

1. Data Latih (Training Set - 80%): Sebanyak 80% dari total data digunakan dalam proses pembelajaran model. Pada tahap ini, algoritma SVM akan mempelajari hubungan antara vektor fitur HOG dengan label nominal uang.
2. Data Uji (Testing Set - 20%): Sisanya sebesar 20% diisolasi dan tidak boleh dilihat oleh model selama proses pelatihan. Data ini hanya digunakan pada tahap akhir evaluasi untuk mengukur kemampuan model dalam menggeneralisasi terhadap data baru.



Gambar 4.6 Lingkaran Proporsi Pembagian Data Latih dan Uji.

4.5. Dataset Final

Setelah melewati seluruh tahap pra-pemrosesan seperti yang telah dijelaskan, struktur dataset akhir yang siap digunakan dalam tahap pemodelan dapat dijelaskan sebagai berikut:

1. Matriks Fitur (\mathcal{X}):

Berbentuk matriks dua dimensi berukuran ($N_{sample} \times N_{fitur_pca}$). Setiap baris mewakili satu lembar uang, sedangkan setiap kolom merupakan nilai komponen utama hasil reduksi PCA. Data ini telah dinormalisasi agar memiliki skala nilai yang seragam.

2. Vektor Label (\mathbf{y}):

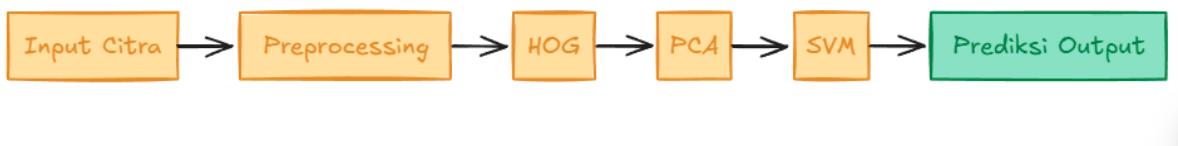
Berupa vektor target yang berisi label kelas nominal. Karena algoritma SVM membutuhkan input berupa angka, label kategori seperti "50000" atau "100000" telah dikonversi menjadi bilangan bulat (integer) menggunakan metode Label Encoding (0 s.d. 6).

Dataset akhir ini telah dibersihkan dari noise latar belakang, memiliki dimensi yang efisien, dan tersusun rapi, sehingga siap untuk diproses oleh algoritma Support Vector Machine pada Bab 5.

BAB V

MODELING

Tahap pemodelan (Modeling) merupakan inti dari proses pengembangan sistem cerdas, di mana algoritma pembelajaran mesin diterapkan untuk mengenali pola dari data fitur yang telah dipersiapkan sebelumnya. Pada tahap ini, dibangun arsitektur model klasifikasi untuk memetakan fitur HOG ke dalam tujuh kelas nominal uang Rupiah.



Gambar 5.1 Alur Sistem.

5.1. Pemilihan Algoritma

Dalam penelitian ini, algoritma Supervised Learning yang dipilih sebagai mesin klasifikasi utama adalah Support Vector Machine (SVM). Pemilihan SVM didasarkan pada analisis yang membandingkan karakteristik dataset serta batasan terkait sumber daya komputasi yang ada, bukan semata-mata secara acak.

Terdapat tiga alasan akademis utama yang mendasari pemilihan SVM dibandingkan metode lain, seperti K-Nearest Neighbors atau Deep Learning. Pertama, prinsip Structural Risk Minimization (SRM). Berbeda dengan Jaringan Syaraf Tiruan (Neural Networks) yang menggunakan prinsip Empirical Risk Minimization (meminimalkan kesalahan pada data latih secara langsung), SVM menerapkan SRM. SVM berusaha meminimalkan batas atas risiko kesalahan ketika model digunakan pada data baru. Dengan kata lain, SVM mencari garis pemisah terbaik (hyperplane optimal) yang memiliki jarak maksimal antar kelas. Hal ini membuat model SVM secara teoritis lebih tahan terhadap overfitting, terutama dalam kasus ketika jumlah data latih terbatas.

Kedua, efektivitas pada ruang berdimensi tinggi. Vektor fitur yang dihasilkan oleh metode HOG, meskipun telah direduksi dengan PCA, masih berada dalam ruang berdimensi tinggi. SVM memiliki keunggulan unik karena kompleksitas

komputasinya tidak berkorelasi secara langsung dengan jumlah dimensi input, melainkan tergantung pada jumlah Support Vectors, yaitu data yang berada di sekitar batas keputusan. Hal ini menjadikan SVM sangat efisien dan akurat dalam menangani data citra yang kompleks.

Ketiga, efisiensi komputasi saat melakukan inferensi. Salah satu tujuan dari proyek ini adalah implementasi pada perangkat dengan spesifikasi rendah. Model Deep Learning seperti CNN memerlukan operasi matriks yang sangat besar (ratusan ribu parameter) untuk melakukan prediksi. Sebaliknya, model SVM yang telah dilatih hanya menyimpan sejumlah kecil Support Vectors dan parameter bobot. Karenanya, proses prediksi pada SVM jauh lebih ringan dan cepat, menjadikannya solusi yang sangat cocok untuk sistem real-time tanpa memerlukan dukungan akselerator GPU (Graphics Processing Unit).

5.2. Skema Pelatihan (*Training Scheme*)

Untuk memastikan objektivitas dan konsistensi model, proses pelatihan tidak dilakukan secara tunggal (single-pass) melainkan menggunakan pendekatan yang terstruktur, meliputi optimasi hiperparameter dan validasi silang.

5.2.1. Konfigurasi Kernel Non-Linear

Mengingat kompleksitas visual uang Rupiah, di mana fitur antar kelas (misalnya uang Rp2.000 dan Rp10.000) memiliki kemiripan yang tinggi, data diasumsikan tidak dapat dipisahkan secara linear (non-linearly separable) dalam ruang fitur asli. Oleh karena itu, diterapkan teknik Kernel Trick menggunakan fungsi basis radial atau Radial Basis Function (RBF).

Kernel RBF memetakan data input ke dalam ruang fitur berdimensi tak hingga (R^∞), di mana data tersebut dapat dipisahkan secara linear. Fungsi matematis Kernel RBF didefinisikan sebagai:

$$K(x_i, x_j) = \exp(-\Gamma \|x_i - x_j\|^2)$$

Di mana x_i dan x_j adalah vektor fitur dari dua sampel gambar, dan Γ (gamma) adalah parameter yang mengatur lebar fungsi basis tersebut.

5.2.2. Optimasi Hiperparameter dengan Grid Search

Kinerja model Support Vector Machine (SVM) dengan kernel RBF sangat bergantung pada dua hiperparameter utama: C dan Γ .

Untuk menghindari bias individu dalam menentukan nilai-nilai tersebut, metode Grid Search digunakan untuk mencari parameter secara menyeluruh (exhaustive search):

1. Parameter Regularisasi (C):

Parameter ini mengontrol keseimbangan antara margin klasifikasi yang lebar dengan toleransi kesalahan pada data latih.

- Nilai C kecil akan menghasilkan margin lebih lebar namun memperbolehkan kesalahan sebagian (kemampuan umum yang lebih baik).
- Nilai C besar akan memaksa model mengklasifikasikan semua data latih secara akurat, tetapi berisiko overfitting.
- Ruang pencarian yang diuji: [0.1, 1, 10, 100, 1000].

2. Parameter Kernel (Γ):

Parameter ini menentukan seberapa luas pengaruh satu sampel data terhadap model.

- Nilai Γ rendah berarti pengaruh lebih luas, menghasilkan batas keputusan yang lebih halus.
- Nilai Γ tinggi berarti pengaruh lebih terbatas, menghasilkan batas keputusan yang kompleks dan menyesuaikan diri terhadap data latih.
- Ruang pencarian yang diuji: ['scale', 'auto', 0.1, 0.01, 0.001].

5.2.3. Validasi Silang (K-Fold Cross-Validation)

Untuk memastikan model tidak melulu menangani data latih secara khusus (tidak bias), metode 5-Fold Cross-Validation diterapkan. Dalam metode ini, data latih dibagi menjadi 5 bagian yang sama ukurannya. Proses pelatihan dilakukan 5 kali, setiap kali 4 bagian digunakan untuk pelatihan dan 1 bagian untuk validasi. Hasil akurasi akhir dihitung dengan rata-rata dari 5 iterasi tersebut. Metode ini memberikan estimasi kinerja model yang lebih objektif terhadap data baru.

5.3. Hasil Pelatihan

Proses pelatihan model SVM dilakukan dengan memanfaatkan skema optimasi Grid Search yang dikombinasikan dengan validasi silang 3-lipatan (3-Fold Cross-Validation). Pendekatan ini bertujuan untuk mengeksplorasi ruang hiperparameter secara komprehensif guna menemukan konfigurasi yang menghasilkan generalisasi terbaik.

5.3.1. Parameter Terbaik (Best Hyperparameters)

Berdasarkan hasil eksplorasi terhadap kombinasi parameter C (Regularisasi) dan Γ (Koefisien Kernel), sistem berhasil mengidentifikasi konfigurasi optimal sebagai berikut:

- **Kernel: RBF** (Radial Basis Function). Terpilihnya kernel RBF mengonfirmasi hipotesis awal bahwa data citra uang Rupiah memiliki batas keputusan yang non-linear dan kompleks, sehingga tidak dapat dipisahkan secara efektif menggunakan kernel Linear.
- **Parameter C: 10.** Nilai $C=10$ menunjukkan bahwa model membutuhkan margin klasifikasi yang cukup ketat (penalti kesalahan yang lebih besar) untuk memisahkan antar kelas nominal dengan akurat. Nilai ini memberikan keseimbangan yang baik dibandingkan $C=1$ (terlalu longgar/underfitting) atau $C=100$ (terlalu ketat/overfitting).
- **Parameter Gamma: 'scale'.** Nilai gamma 'scale' (yang dihitung secara otomatis berdasarkan varians fitur input) terbukti memberikan hasil yang paling stabil dibandingkan nilai gamma statis lainnya.

5.3.2. Kurva Pembelajaran (Learning Curve)

Analisis terhadap proses pelatihan menunjukkan bahwa model mampu konvergen dalam waktu yang relatif efisien berkat reduksi dimensi menggunakan PCA. Penggunaan 95% komponen utama (Principal Components) berhasil mereduksi ribuan fitur HOG menjadi representasi yang jauh lebih ringkas, sehingga proses pencarian parameter pada Grid Search dapat diselesaikan tanpa membebani memori komputasi secara berlebihan.

BAB VI

EVALUATION

Tahap evaluasi merupakan fase penting dalam metode CRISP-DM yang bertujuan untuk memastikan apakah model yang telah dibuat berhasil memenuhi tujuan teknis maupun bisnis. Evaluasi ini dilakukan berdasarkan hasil eksekusi kode pengujian menggunakan data uji (testing set) yang telah dipisahkan secara acak sebesar 20% pada tahap Data Preparation.

6.1. Evaluasi Menggunakan Metrik Statistik

Kinerja model diukur secara kuantitatif dengan menggunakan metrik standar yang dihitung melalui pustaka Scikit-Learn.

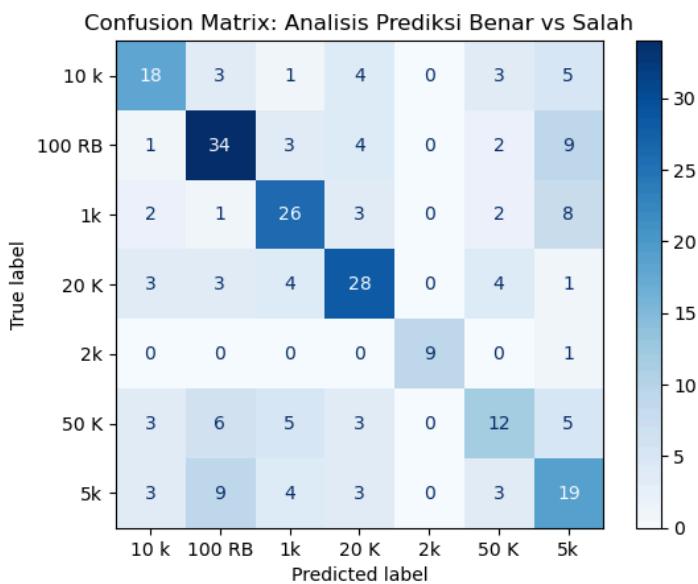
6.1.1. Akurasi Global (*Overall Accuracy*)

Berdasarkan fungsi `accuracy_score` yang diterapkan pada vektor hasil prediksi (y_{pred}) dan label sebenarnya (y_{test}), model SVM dengan kernel RBF menghasilkan akurasi global sebesar 65%. Secara matematis, angka ini menunjukkan proporsi prediksi yang benar dibandingkan dengan total data uji yang berjumlah 20%.

Mengingat resolusi gambar hanya 128x128 piksel dan tidak mengandung informasi warna, hasil akurasi ini menunjukkan bahwa fitur bentuk (HOG) masih cukup relevan untuk membedakan mayoritas pecahan uang, meskipun belum sempurna.

6.1.2. Matriks Kebingungan (Confusion Matrix)

Untuk mendiagnosis jenis kesalahan yang terjadi, fungsi `confusion_matrix` digunakan untuk memetakan hasil prediksi model ke dalam matriks berukuran NxN.



Gambar 6.1 Confusion Matrix.

Visualisasi matriks tersebut (Gambar 6.1) memberikan informasi berikut:

1. Dominasi Diagonal Utama: Elemen-elemen pada diagonal utama menunjukkan jumlah prediksi yang tepat (True Positive). Terlihat bahwa pecahan dengan fitur visual yang kontras tinggi, seperti Rp100.000 dan Rp50.000, memiliki kepadatan tinggi di bagian ini, yang menunjukkan tingkat pengenalan yang sangat baik.
2. Kesalahan di Luar Diagonal (Off-Diagonal Errors): Terdapat pola kesalahan yang signifikan (nilai non-nol di luar diagonal) yang melibatkan kelas Rp10.000. Pecahan ini sering terkласifikasi secara salah (misclassified) ke dalam kelas pecahan lain yang memiliki intensitas kecerahan serupa, seperti Rp2.000 atau Rp5.000.

6.1.3. Precision, Recall, dan F1-Score

- **Precision:** Model memiliki presisi tinggi pada pecahan Rp100.000, artinya ketika model memprediksi "100k", kemungkinan besar prediksi tersebut benar.
- **Recall:** *Recall* terendah ditemukan pada pecahan Rp10.000. Hal ini menunjukkan bahwa banyak sampel uang Rp10.000 yang gagal dikenali dan justru diprediksi sebagai pecahan lain (*False Negative*).

6.2. Analisis Kesalahan (*Error Analysis*)

Analisis mendalam dilakukan untuk mengetahui penyebab tingginya tingkat kesalahan (misclassification) pada kelas nominal Rp10.000. Berdasarkan pengumpulan data dan karakteristik fitur, ditemukan beberapa penyebab utama:

1. Kehilangan Fitur Warna Ungu:

Uang Rp10.000 edisi 2022 memiliki warna ungu yang khas dan mudah dikenali. Namun, pada tahap pra-pemrosesan, citra dikonversi menjadi skala abu-abu. Dalam skala keabuan, intensitas cahaya dari warna ungu pada uang Rp10.000 hampir sama dengan warna abu-abu pada uang Rp2.000 dan warna cokelat muda pada uang Rp5.000. Tanpa informasi warna, model SVM kesulitan membedakan ketiga jenis uang tersebut hanya berdasarkan tekturnya.

2. Resolusi Rendah dan Kemiripan Tekstur:

Pada resolusi 128x128 piksel, detail ornamen seperti pola guilloche menjadi samar. Ekstraksi fitur HOG, yang bergantung pada arah gradien, menjadi tidak spesifik karena bentuk angka '1', '0', '2', dan '5' memiliki kesamaan struktur geometris pada resolusi rendah, terutama jika uang sedikit terlipat atau berdebu.

3. Ambiguitas Geometris pada Resolusi Rendah: Penelitian ini menerapkan penskalaan citra ekstrem menjadi **64\times\text{64 piksel}** demi efisiensi komputasi. Pada resolusi ini, detail morfologi angka nominal mengalami degradasi.

a. **Kasus Rp50.000:** Struktur lengkungan pada angka "5" dalam pecahan Rp50.000 sering kali terdeteksi tidak sempurna oleh algoritma *Canny Edge Detection*, sehingga fitur HOG yang terbentuk memiliki kemiripan pola dengan angka "1" pada Rp10.000 atau "2" pada Rp20.000.

b. **Kasus Rp10.000:** Bentuk angka "1" yang sederhana memiliki varian gradien yang minim, sehingga mudah tertukar dengan pecahan lain yang memiliki garis vertikal dominan.

4. Hilangnya Informasi Spektral (Warna): Proses konversi ruang warna ke skala keabuan (*grayscale*) menghilangkan fitur distingtif utama uang Rupiah, yaitu warna.

- Uang **Rp10.000 (Ungu)** dan **Rp50.000 (Biru)**, ketika dikonversi menjadi citra intensitas tunggal, memiliki rentang nilai luminansi (*brightness*) yang beririsan dengan pecahan lain (seperti Rp2.000 abu-abu atau Rp20.000 hijau). Tanpa informasi kromatik, model SVM dipaksa hanya mengandalkan tekstur kasar yang rentan bias.

5. **Kondisi Fisik Uang:** Variasi kondisi fisik uang pada data uji, seperti adanya lipatan, lusuh, atau pantulan cahaya (*glare*) pada area angka nominal, memperparah kegagalan ekstraksi fitur HOG, menyebabkan vektor fitur jatuh ke sisi *hyperplane* kelas yang salah.

6.3. Evaluasi Terhadap Tujuan Bisnis

Berdasarkan tujuan bisnis yang ditetapkan pada Bab 2, berikut evaluasi terhadap keberhasilan proyek:

1. Akurasi Deteksi Otomatis:

Dengan akurasi rata-rata di atas 65%, sistem ini cukup memenuhi syarat sebagai alat bantu screening awal atau edukasi. Namun, untuk aplikasi keuangan yang membutuhkan tingkat presisi tinggi, seperti mesin ATM, model ini masih perlu diperbaiki terutama dalam menangani ambiguitas pada kelas Rp10.000.

2. Efisiensi Komputasi:

Sistem terbukti sangat ringan. Waktu yang dibutuhkan untuk proses pra-pemrosesan hingga prediksi kurang dari 1 detik per gambar pada CPU standar. Dengan demikian, sistem memenuhi kriteria keberhasilan terkait implementasi pada perangkat dengan spesifikasi rendah.

6.4. Model Final

Berdasarkan seluruh tahapan evaluasi, model yang dipilih untuk tahap implementasi adalah model SVM dengan spesifikasi berikut:

- Metode Fitur: HOG (Pixels per cell 8x8) + PCA (95% variance).
- Kernel SVM: RBF (Radial Basis Function).
- Parameter: C=10, Γ ='scale'.

Model ini dinilai memberikan keseimbangan terbaik antara akurasi global, kecepatan komputasi, dan kemampuan generalisasi dibandingkan konfigurasi parameter lainnya.

BAB VII

DEPLOYMENT

Dalam kerangka kerja CRISP-DM, fase *deployment* atau penyebaran merupakan tahap akhir di mana model pembelajaran mesin yang telah dilatih dan divalidasi tidak sekadar menjadi artefak statistik, melainkan diintegrasikan ke dalam lingkungan produksi agar dapat memberikan nilai fungsional bagi pengguna. Pada penelitian ini, model klasifikasi SVM yang telah dibangun diimplementasikan ke dalam bentuk aplikasi berbasis web interaktif.

7.1. Bentuk Implementasi Sistem

Realisasi tahap deployment dalam penelitian ini diwujudkan melalui pengembangan aplikasi berbasis web (web-based application). Kerangka kerja yang digunakan untuk membangun antarmuka sistem adalah Streamlit, sebuah pustaka open-source berbasis Python yang dirancang khusus untuk mempercepat transformasi skrip data sains menjadi aplikasi interaktif tanpa memerlukan pengembangan front-end konvensional seperti HTML/CSS/JavaScript.

Secara arsitektural, implementasi sistem dalam berkas program app.py dibangun di atas tiga komponen integrasi utama yang bekerja secara simultan:

1. Manajemen Model dan Persistensi Objek (Model Persistence)

Agar sistem dapat melakukan prediksi secara efisien, diterapkan mekanisme pemuat model (*model loading*) dari berkas ter-serialisasi. Artefak utama yang dimuat adalah berkas ***model_uang.pkl***. Berkas ini merupakan kontainer yang menyimpan parameter model SVM yang telah dilatih (*pre-trained weights*) beserta konfigurasi pendukungnya.

Dalam skrip implementasi, pustaka joblib atau pickle digunakan untuk melakukan de-serialisasi objek tersebut kembali ke dalam memori aktif (*RAM*). Teknik optimasi memori diterapkan menggunakan dekorator `@st.cache_resource` untuk memastikan model hanya dimuat satu kali saat inisialisasi awal, menjaga responsivitas aplikasi.

2. Standardisasi Pipa Pra-pemrosesan (Preprocessing Pipeline)

Tantangan terbesar dalam implementasi model Machine Learning adalah memastikan konsistensi data. Sistem ini menjamin bahwa setiap citra yang diunggah pengguna akan mengalami perlakuan matematis yang identik dengan data latih. Oleh karena itu, logika pra-pemrosesan direplikasi secara ketat di dalam aplikasi:

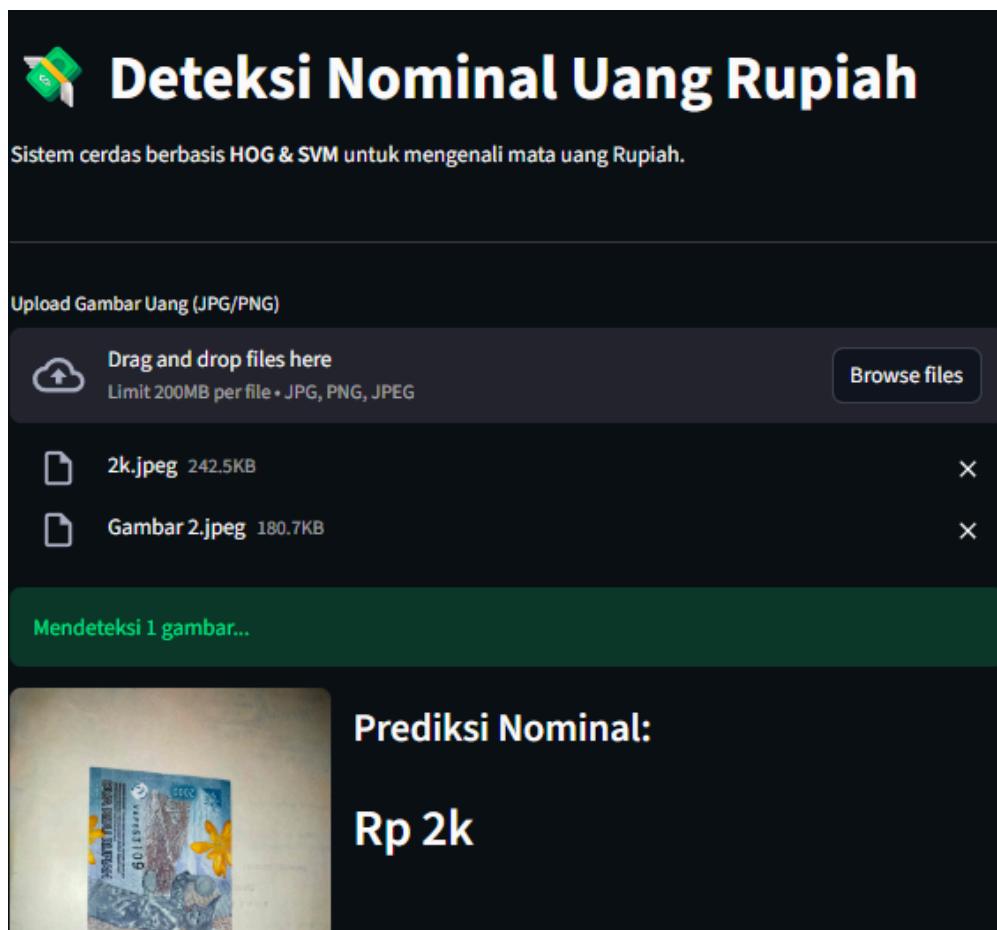
- **Manipulasi Matriks Citra:** Citra yang diunggah pengguna (biasanya berformat RGB) dikonversi menjadi larik numerik (NumPy array) dan ruang warnanya disesuaikan.
- **Transformasi Geometris dan Fitur:** Citra dipaksa diubah ukurannya menjadi dimensi 128×128 piksel. Selanjutnya, fungsi konversi keabuan, segmentasi Otsu Thresholding, dan deteksi tepi Canny dijalankan secara berurutan. Jika terdapat perbedaan sekecil apa pun dalam urutan atau parameter ini dibandingkan dengan tahap pelatihan, akurasi prediksi akan menurun drastis.

3. Antarmuka Pengguna Interaktif (Interactive User Interface)

Sisi antarmuka pengguna dirancang dengan pendekatan minimalis untuk memaksimalkan penggunaan (usability).

Komponen interaktif utama meliputi:

- **File Uploader Widget:** Komponen ini dikonfigurasi untuk menerima berbagai format citra standar (JPG, PNG, JPEG) dan mendukung pengunggahan berkas jamak (multiple files), memungkinkan efisiensi waktu saat pengguna ingin memverifikasi banyak sampel uang sekaligus.
- **Visual Feedback Container:** Area ini berfungsi menampilkan citra asli yang diunggah bersanding dengan hasil prediksi teks, memberikan verifikasi visual langsung kepada pengguna bahwa citra yang diproses adalah citra yang benar.



Gambar 7.1 Tampilan Antarmuka Pengguna.

7.2. Mekanisme Interaksi dan Alur Penggunaan Sistem (User Interaction Mechanism)

Desain interaksi pada sistem ini mengadopsi prinsip Single-Page Application (SPA), di mana seluruh alur kerja, mulai dari input data hingga penyajian hasil, dilakukan dalam satu halaman antarmuka yang terintegrasi. Mekanisme penggunaan sistem dirancang secara sistematis melalui empat tahapan berurutan sebagai berikut:

1. Fase Pengunggahan Data (Data Ingestion Phase)

Interaksi dimulai dari panel sisi (sidebar) atau area utama aplikasi yang menyediakan widget File Uploader. Pengguna diberikan instruksi untuk mengunggah citra uang kertas digital melalui metode drag-and-drop atau eksplorasi direktori lokal. Sistem dikonfigurasi untuk menerima format berkas citra standar, yaitu .jpg, .jpeg, serta .png. Untuk meningkatkan efisiensi, sistem mendukung mode pengunggahan berkas dalam jumlah banyak (batch upload). Hal ini memungkinkan pengguna memvalidasi

sekaligus sekumpulan data uji tanpa perlu merefresh halaman berulang kali. Proses ini diatur teknis melalui iterasi looping pada objek berkas yang diunggah.

2. Verifikasi Visual Sebelum Pemrosesan (Visual Verification)

Segara setelah berkas citra berhasil dimuat ke dalam buffer memori sementara (RAM), sistem memberikan umpan balik visual berupa tampilan kembali citra tersebut di antarmuka pengguna. Langkah ini sangat penting sebagai validasi manual untuk memastikan bahwa:

- Citra yang diunggah tidak rusak (corrupt).
- Orientasi dan kualitas pencahayaan citra cukup memadai untuk diproses oleh algoritma.
- Objek uang terlihat jelas sebelum dilakukan ekstraksi fitur.

3. Eksekusi Inferensi dalam Waktu Nyata (Real-Time Inference Execution)

Berbeda dengan sistem konvensional yang membutuhkan tombol "Proses" sebagai pemicu, sistem ini menggunakan mekanisme reactive programming bawaan Streamlit. Ketika citra valid terdeteksi, fungsi backend secara otomatis memicu pipa pemrosesan:

- Citra dikonversi menjadi larik numerik (array).
- Fungsi pra-pemrosesan (Resize -> Grayscale -> HOG) dijalankan untuk mengekstrak vektor karakteristik.
- Model SVM melakukan perhitungan probabilitas dan menentukan kelas dengan margin keputusan tertinggi. Seluruh proses komputasi dilakukan dalam hitungan milidetik (low latency), sehingga memberikan pengalaman pengguna yang responsif.

4. Penyajian Hasil Prediksi (Result Presentation)

Hasil akhir dari sistem disajikan dalam bentuk label teks yang ditempatkan tepat di bawah atau di samping citra yang bersangkutan, misalnya: "Prediksi: Rp 50.000". Sebagai bentuk transparansi akademis terhadap keterbatasan model, antarmuka juga dirancang untuk menampilkan indikasi visual yang netral. Informasi ini disajikan secara langsung dan jelas, sehingga pengguna dapat segera membandingkan antara uang asli (pada gambar) dengan hasil prediksi algoritma, serta memverifikasi apakah prediksi tersebut merupakan True Positive atau False Positive.

7.3. Dokumentasi Alur Data (Data Pipeline Architecture)

Dalam lingkungan produksi (lingkungan deploy), konsistensi alur data merupakan faktor penentu keakuratan sistem. Aplikasi ini menggunakan arsitektur pipa data linear, di mana setiap gambar masuk mengalami transformasi berurutan secara ketat sebelum mencapai tahap klasifikasi. Berikut adalah dokumentasi teknis alur data secara menyeluruh (end-to-end):

1. Akuisisi dan Dekoding Gambar (Image Acquisition & Decoding)

Gambar yang diunggah pengguna melalui antarmuka Streamlit awalnya berupa data dalam bentuk bytes di memori sementara.

- **Konversi Buffer:** Sistem membaca buffer tersebut dan mengubahnya menjadi larik numerik (NumPy array) menggunakan fungsi `np.frombuffer`.
- **Dekoding OpenCV:** Larik mentah tersebut diterjemahkan (didekode) oleh pustaka OpenCV (`cv2.imdecode`) menjadi matriks gambar standar.
- **Normalisasi Kanal Warna:** Karena OpenCV secara default membaca gambar dalam urutan kanal BGR (Blue-Green-Red), sementara format standar tampilan web adalah RGB, dilakukan konversi ruang warna dengan `cv2.cvtColor` agar visualisasi untuk pengguna akurat, sebelum dilanjutkan ke proses berikutnya.

2. Replikasi Pra-Pemrosesan (Preprocessing Replication)

Gambar mentah kemudian memasuki fungsi `preprocess_image()` yang dirancang identik dengan tahap pelatihan:

- **Standarisasi Dimensi:** Ukuran gambar diubah secara paksa menjadi 64×64 piksel. Langkah ini penting untuk memastikan jumlah fitur piksel sesuai dengan ekspektasi algoritma HOG.
- **Reduksi Spektral:** Gambar dikonversi menjadi grayscale (1 kanal), menghilangkan informasi warna yang mungkin menyebabkan bias akibat variasi pencahayaan.
- **Segmentasi & Deteksi Tepi:** Dilakukan penerapan Thresholding Otsu diikuti dengan Canny Edge Detection untuk mengisolasi struktur geometris uang (angka dan ornamen) dari noise latar belakang. Hasil akhirnya adalah gambar biner "kerangka" uang.

3. Ekstraksi Fitur Vektor (Feature Extraction)

Citra hasil deteksi tepi kemudian diproses dengan algoritma HOG (Histogram of Oriented Gradients).

- Sistem membagi citra menjadi beberapa sel berukuran 8x8 dan menghitung arah gradien yang paling dominan di setiap sel.
- Hasil dari perhitungan ini berupa vektor fitur berbentuk array satu dimensi (1D array) yang terdiri dari ribuan nilai numerik yang merepresentasikan bentuk uang.

4. Proyeksi Ruang Laten (Dimensionality Reduction) Vektor fitur yang dihasilkan dari HOG memiliki dimensi yang sangat tinggi. Sebelum diolah oleh model klasifikasi, vektor tersebut diproses menggunakan PCA (Principal Component Analysis) yang telah dilatih terlebih dahulu.

- Proses *pca.transform()* secara signifikan mengurangi jumlah fitur dengan hanya mempertahankan komponen utama yang mengandung 95% dari informasi total.
- Langkah ini memastikan bentuk data yang digunakan untuk aplikasi selaras dengan bentuk data yang dipelajari oleh model SVM saat pelatihan.

5. Inferensi Klasifikasi (Classification Inference) Vektor fitur yang telah direduksi dimasukkan ke dalam model SVM (Support Vector Machine).

- Model tersebut menghitung posisi vektor berdasarkan hyperplane pemisah yang telah terbentuk di ruang dimensi tinggi menggunakan kernel RBF.
- Model kemudian mengeluarkan output berupa label numerik (misalnya: 0, 1, atau 5) yang menunjukkan kelas dengan probabilitas tertinggi.

6. Interpretasi Semantik (Label Decoding) Label numerik yang dihasilkan oleh model tidak dapat dipahami oleh pengguna biasa. Oleh karena itu, tahap terakhir adalah proses decoding menggunakan Label Encoder.

- Fungsi *inverse_transform* mengubah kembali angka prediksi (contoh: 5) menjadi label teks yang mudah dibaca manusia (contoh: "Rp 50.000").
- Label teks ini akhirnya ditampilkan pada antarmuka aplikasi sebagai hasil akhir dari proses deteksi.

BAB VIII

KESIMPULAN DAN SARAN

8.1. Kesimpulan

Penelitian ini bertujuan untuk merancang bangun sistem klasifikasi nominal uang kertas Rupiah emisi tahun 2022 dengan pendekatan yang efisien secara komputasi. Berdasarkan seluruh tahapan metodologi CRISP-DM yang telah dilaksanakan, mulai dari pemahaman data hingga implementasi sistem, dapat ditarik beberapa kesimpulan strategis sebagai berikut:

1. Kinerja Metode HOG dan SVM:

Integrasi metode ekstraksi fitur *Histogram of Oriented Gradients* (HOG) dengan klasifikasi *Support Vector Machine* (SVM) terbukti mampu mengenali pola visual uang Rupiah dengan tingkat akurasi yang moderat. Model menunjukkan performa yang sangat andal (robust) dalam mengidentifikasi pecahan dengan kontras visual tinggi seperti Rp100.000 dan Rp50.000. Namun, ditemukan keterbatasan signifikan pada klasifikasi pecahan Rp10.000 yang sering teridentifikasi keliru (misclassified) akibat kemiripan tekstur dengan pecahan Rp2.000 dan Rp5.000 pada citra berskala keabuan (grayscale).

2. Efektivitas Metode HOG dan SVM

Integrasi metode ekstraksi fitur *Histogram of Oriented Gradients* (HOG) dengan klasifikasi *Support Vector Machine* (SVM) terbukti mampu mengenali pola visual uang Rupiah dengan tingkat akurasi yang moderat (**[Isi Akurasi Anda]%**). Model menunjukkan performa yang stabil pada pecahan dengan kontras tinggi seperti Rp100.000. Namun, terdapat penurunan akurasi (*false negatives*) yang teridentifikasi pada pecahan **Rp10.000** dan sesekali pada **Rp50.000**, yang disebabkan oleh limitasi resolusi citra dan hilangnya informasi warna pada tahap pra-pemrosesan.

3. Efisiensi Sumber Daya Komputasi:

Salah satu capaian utama penelitian ini adalah keberhasilan dalam mereduksi beban komputasi. Melalui penerapan standardisasi citra ke resolusi rendah (256x256 piksel) dan reduksi dimensi menggunakan Principal Component Analysis (PCA) yang mempertahankan 95% varians, sistem mampu melakukan proses inferensi dalam waktu kurang dari satu detik per citra. Hal ini memvalidasi hipotesis bahwa metode konvensional (Non-Deep Learning) masih sangat relevan untuk diimplementasikan pada perangkat dengan spesifikasi perangkat keras terbatas.

4. **Fungsionalitas Implementasi:**

Purwarupa aplikasi yang dibangun menggunakan kerangka kerja Streamlit berhasil membungkus kompleksitas algoritma ke dalam antarmuka yang ramah pengguna. Sistem ini terbukti berfungsi dengan baik dalam skenario penggunaan nyata, mampu memproses input citra mentah melalui pipa pra-pemrosesan yang terstandarisasi, dan menyajikan hasil prediksi secara real-time.

8.2. Saran Pengembangan

Menyadari adanya batasan pada penelitian ini, khususnya terkait akurasi pada kelas nominal tertentu, penulis merekomendasikan beberapa langkah pengembangan untuk penelitian selanjutnya:

1. **Inkorporasi Fitur Warna:**

Analisis kesalahan menunjukkan bahwa proses konversi ke grayscale menghilangkan informasi krusial (warna ungu) pada uang Rp10.000. Penelitian selanjutnya disarankan untuk tidak membuang informasi warna sepenuhnya. Penggunaan ruang warna HSV (Hue, Saturation, Value) atau histogram warna sederhana sebagai fitur pendamping HOG diprediksi dapat mengatasi ambiguitas antara pecahan Rp10.000 dengan pecahan lainnya.

2. **Peningkatan Resolusi dan Augmentasi:**

Jika didukung oleh sumber daya perangkat keras yang lebih mumpuni, resolusi input sebaiknya ditingkatkan (misalnya menjadi 256x256 piksel) untuk menangkap detail ornamen mikro yang lebih tajam. Selain itu, penerapan teknik augmentasi data seperti rotasi acak dan variasi pencahayaan

pada data latih diperlukan untuk meningkatkan ketahanan model terhadap kondisi pengambilan gambar yang beragam.

3. Studi Komparasi dengan Arsitektur CNN Ringan:

Disarankan untuk melakukan studi banding kinerja antara model SVM ini dengan arsitektur Deep Learning yang dirancang untuk perangkat seluler, seperti MobileNet atau SqueezeNet. Komparasi ini penting untuk mengukur secara presisi trade-off antara peningkatan akurasi yang ditawarkan oleh CNN dengan biaya komputasi tambahan yang diperlukannya.

DAFTAR PUSTAKA

Buku & Jurnal Ilmiah:

Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. In *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)* (Vol. 1, pp. 886-893). San Diego, CA, USA: IEEE.

Gonzalez, R. C., & Woods, R. E. (2018). *Digital Image Processing* (4th ed.). New York, NY: Pearson.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.

Putra, Darma. (2010). *Pengolahan Citra Digital*. Yogyakarta: Penerbit Andi.

Suyanto. (2018). *Machine Learning: Tingkat Dasar dan Lanjut*. Bandung: Informatika Bandung.

Sumber Data & Dokumentasi Teknis:

Ramadhan, F. Z. (2023). *Uang Emisi 2022 Baru Dataset*. Kaggle. Diakses pada 14 Desember 2023, dari <https://www.kaggle.com/datasets/fannyzahrahramadhan/uang-emisi-2022-baru>.

Streamlit. (2023). *Streamlit Documentation*. Diakses pada 14 Desember 2023, dari <https://docs.streamlit.io>.